CENG468 Veri Madenciliği

2026-2027 Güz · Hafta 5

Öğr. Gör. Dr. Duygu TOPALOĞLU

Bugün Neler Yapacağız?



Veriyi tanımak

NumPy ve pandas; Series, DataFrame, index



Temizlik kararı

Tuhaf satırlar, maske, karar tablosu, kod



İlk öneri sistemi

groupby: en çok satanlar



Ülkeye göre

Kişiselleştirmeye ilk adım; soğuk başlangıç



Sepet analizi

"Bunu alan şunu da aldı": mantığı

NumPy ve pandas: Kısa Bir Tanışma

NumPy: Sayısal Hesabın Temeli

Nedir?
Numerical Python

- Çok boyutlu sayı dizisi: ndarray
- Döngü yazmadan bütün diziye tek işlem
- Hızlı: çekirdeği C ile yazılmış

Kaynak: numpy.org

Ne zaman?
Kısa tarih

- 1995: Numeric (Jim Hugunin)
- 2005: Travis Oliphant, Numeric ile Numarray'i birleştirir
- 2006: NumPy 1.0

Bizde: numpy 2.5.3

Nerede?
Kim kullanıyor?

- Bilimsel Python'un temeli: pandas, scikit-learn, matplotlib onun üzerine kurulu
- Kütleçekim dalgalarının keşfi
- İlk kara delik görüntüsü

pandas: Tablo Verisinin Aracı



Nedir?

Python data analysis

- DataFrame: satır ve sütunlardan oluşan tablo
- Excel, CSV, SQL okur ve yazar
- Eksik veri, gruplama, birleştirme, zaman serisi

Kaynak: pandas.pydata.org



Ne zaman?

Kısa tarih

- 2008: Wes McKinney, AQR Capital (finans şirketi)
- 2009: açık kaynak oldu
- 2020: 1.0 · 2023: 2.0 · Ocak 2026: 3.0

Adı: panel data + Python data analysis



Nerede?

Kim kullanıyor?

- Finans, ekonomi, istatistik
- Nörobilim, reklam, web analitiği
- Bu derste: 541.910 satırlık Online Retail

Kısa Tarih: Numeric'ten pandas 3'e

1995

Numeric

Kim?

Jim Hugunin. Python'daki ilk dizi paketi

2006

NumPy 1.0

Kim?

Travis Oliphant. Numeric ve Numarray tek pakette

2009

pandas açık kaynak

Kim?

Wes McKinney. 2008'de bir finans şirketinde başladı

2026

pandas 3.0

Bizim sürüm

Ocak 2026. Metin sütunları artık str tipinde; bizde 3.0.6

İkisi de açık kaynak ve ücretsiz; NumFOCUS çatısı altında gönüllü topluluklar geliştiriyor.

NumPy mı, pandas mı?

NumPy
Aynı tipte sayılardan oluşan dizi

Vektör ve matris: adetler * fiyatlar

İleride: benzerlik ve iç çarpım (öneri sistemleri)

pandas
Sütunları adlı, tipleri farklı tablo

Invoice metin, Quantity sayı, InvoiceDate tarih: aynı tabloda

Sayısal sütunlar arka planda NumPy dizisidir

Bu derste

Veriyi pandas ile okur, süzer ve özetleriz. Hesabı çoğu zaman NumPy yapar; biz görmeyiz.

Pandas ile Veriyi Okumak ve Süzmek

DataFrame, Series ve Index

index	Invoice	Quantity	Country
0	536365	6	United Kingdom
1	536365	6	United Kingdom
2	536365	8	United Kingdom
3	536365	6	United Kingdom
4	536365	6	United Kingdom
5	536365	2	United Kingdom
6	536365	6	United Kingdom

df: bir DataFrame

Satırların adı index (0, 1, 2 …), sütunların adı başlık

Tek sütun = Series

df["Quantity"] → Series, shape (541910,) · df[["Invoice", "Quantity"]] → DataFrame, shape (541910, 2)

Series ≈ sözlük: etiket → değer

Veriyi Okumak: Excel'den CSV'ye

1	**Yolu tut**	VERI = "Veri/online_retail" · Yol, ders klasörüne (ceng468) göredir.
2	**Excel'i oku**	pd.read_excel(XLSX, sheet_name="Year 2010-2011", dtype={"Invoice": str, "StockCode": str}) · İlk seferde 30 sn – 2 dk.
3	**CSV olarak sakla**	df.to_csv(CSV, index=False) · Aynı klasöre, yalnız ilk açılışta.
4	**Sonra hep CSV**	pd.read_csv(CSV, …) · Birkaç saniye. Defterdeki if bu seçimi kendisi yapar.

Hangi Soru, Hangi Komut?

Soru	Komut	Ne döner?	Online Retail'de
İlk satırlar neye benziyor?	df.head()	İlk 5 satır	Fatura 536365'in ürünleri
Kaç satır, kaç sütun?	df.shape	(satır, sütun)	(541910, 8)
Sütunların tipi ne?	df.info()	Tip ve dolu sayısı	Invoice: str · Quantity: int64
Sayısal özet?	df.describe()	Ort., std, min, max	Quantity ortalaması 9,55
En sık değerler?	df["Country"].value_counts()	Değer başına sayım	United Kingdom: 495.478
Kaç farklı, kaç boş?	.nunique() · .isnull().sum()	Sayı	38 ülke · 135.080 boş müşteri

pandas 3 notu

Metin sütunları artık object değil str görünür. İnternetteki eski örneklerde object yazar; ikisi de 'metin' demek.

value_counts() Bir Series Döndürür

Index = etiket

Solda ülke adları (index), sağda sayılar (değer). Index artık 0, 1, 2 değil: anlamlı bir etiket.

ulkeler = df["Country"].value_counts()

9.495

Etiketle oku, sözlük gibi: Almanya'dan 9.495 satır. Sırayla oku: 3. sıradaki ülke France, değeri 8.558.

ulkeler["Germany"] · ulkeler.index[2] · ulkeler.iloc[2]

groupby sonuçları da böyle: index'te ürün adları, değerlerde sayılar. Bölüm 4'te top_adet.index[0] = listenin başındaki ürün.

Boolean Maske: Soruyu Sütuna Sor

True / False

Maske: her satır için bir cevap. 541.910 satır, 541.910 True/False.

iptal = df["Invoice"].str.startswith("C")

9.288

df[maske]: yalnız True olan satırlar kalır. iptal.sum() True'ları sayar.

df[iptal]

Maske bir soru, df[maske] onun cevabı. Geçen haftaki for + if döngüsünü tek satırda yapar.

.loc: Satırı ve Sütunu Birlikte Seç

Soru	Yazım	Ne döner?	Online Retail'de
İptal satırlarının hepsi	df[iptal]	DataFrame	9.288 satır × 8 sütun
İptallerde yalnız adet	df.loc[iptal, "Quantity"]	Series	9.288 değer
İptallerde iki sütun	df.loc[iptal, ["Invoice", "Quantity"]]	DataFrame	9.288 × 2
Kaç iptal var?	iptal.sum()	Sayı (True = 1)	9.288
İptal oranı?	iptal.mean()	Sayı (oran)	0,0171 (%1,7)

Kural: virgülden önce satırlar, sonra sütunlar

df.loc[satırlar, sütunlar]. pandas 3'te df[iptal]["Quantity"] = … ile değer atamak çalışmaz; .loc alışkanlığı edinin.

Koşulları Birleştirmek: & | ~

&

ve: ikisi de doğru

(df["Quantity"] < 0) & (~iptal) → iptal değil ama adedi eksi

|

veya: en az biri doğru

(df["Price"] <= 0) | (df["Customer ID"].isnull())

~

değil: tersini al

~iptal → iptal olmayan satırlar

Parantezi unutma: hata vermeyen yanlış

df[df["Quantity"] < 0 & ~iptal] → 10.624 satır (yanlış) · df[(df["Quantity"] < 0) & (~iptal)] → 1.336 satır (doğru)

.str: Metin Sütununa Soru Sormak

startswith	df["Invoice"].str.startswith("C") → 9.288 satır True: iptaller
[0]	df["Invoice"].str[0].value_counts() → 5: 532.619 · C: 9.288 · A: 3
isdigit	~df["StockCode"].str[0].str.isdigit() → ürün olmayan kodlar: POST, M, D …
lower	"Damaged" ile "damaged" aynı olsun diye küçük harfe çevir
contains	df["Description"].str.contains("HEART") → adında HEART geçen ürünler



Hangi Satırlar Kalmalı?

Kararı Koda Dökmek

Adım	Maske (tutulacaklar = True)	Çıkan	Kalan
1 İptal faturalar	~d["Invoice"].str.startswith("C")	9.288	532.622
2 'A' faturalar	~d["Invoice"].str.startswith("A")	3	532.619
3 Adet ≤ 0	d["Quantity"] > 0	1.336	531.283
4 Fiyat ≤ 0	d["Price"] > 0	1.179	530.104
5 Ürün dışı kod	d["StockCode"].str[0].str.isdigit()	2.379	527.725
6 Tekrarlı satır	~d.duplicated()	5.221	522.504

541.910 → 522.504 satır (%96,4)

Bölüm 2'de "tuhaf olanları" aradık, şimdi "tutacaklarımızı" yazıyoruz: yön tersine döndü. Kalan sayısı artarsa yanlış tabloyla başlamışsın.

groupby: Böl, Uygula, Birleştir

1

Böl

mini.groupby("Urun") → satırları ürüne göre ayır: Çay (3 satır), Süt (2), Ekmek (1)

2

Uygula

["Adet"].sum() → her grupta hesap: Çay 2 + 1 + 5 = 8

3

Birleştir

Sonuç bir Series: index = ürün adı. Ekmek 30 · Süt 3 · Çay 8

Anahtarı değiştir, bakış açın değişir

groupby("Urun") → ürün açısından (popülerlik) · groupby("Fatura")["Adet"].sum() → sepet açısından: 1: 3 · 2: 33 · 3: 5

"Popüler" Ne Demek?

Sıra	Toplam adede göre	Fatura sayısına göre	Müşteri sayısına göre
1	PAPER CRAFT, LITTLE BIRDIE · 80.995	WHITE HANGING HEART T-LIGHT HOLDER · 2.256	REGENCY CAKESTAND 3 TIER · 881
2	MEDIUM CERAMIC TOP STORAGE JAR · 78.033	JUMBO BAG RED RETROSPOT · 2.089	WHITE HANGING HEART T-LIGHT HOLDER · 856
3	WORLD WAR 2 GLIDERS ASSTD DESIGNS · 54.951	REGENCY CAKESTAND 3 TIER · 1.988	PARTY BUNTING · 708
4	JUMBO BAG RED RETROSPOT · 48.371	PARTY BUNTING · 1.685	ASSORTED COLOUR BIRD ORNAMENT · 678
5	WHITE HANGING HEART T-LIGHT HOLDER · 37.872	LUNCH BAG RED RETROSPOT · 1.564	SET OF 3 CAKE TINS PANTRY DESIGN · 640

1. sıra tek bir sipariş: 80.995 adet satıldı, 12 dakika sonra iptal edildi

İptal satırını çıkardık, iptal edilen satışı çıkarmadık. Adet ve fatura listelerinin ilk 10'unda yalnız 4 ortak ürün var. Ölçüyü amaç belirler.

Kişiselleştirmeye İlk Adım

1

Herkese aynı liste

En çok satanlar. Kimseyi tanımadan çalışır. (Bugün)

2

Gruba göre liste

Ülkeye göre en çok satanlar. Almanya'da 1. sıra ROUND SNACK BOXES SET OF4 WOODLAND (112 fatura); genel ilk 5'te yok.

3

Kişiye göre öneri

Sepete ya da geçmişe göre. Sepet analizi, işbirlikçi filtreleme: önümüzdeki haftalar.

Soğuk başlangıç

Hakkında veri yoksa (en_cok_satan(df_temiz, "Turkey") → boş liste) bir üst basamağa dön: herkese aynı liste. Boş ekran göstermek de bir öneri kararıdır, kötü bir karar.

Sepet Analizi: Bunu Alan Şunu da Aldı

Kavram	Ne soruyor?	Hesap	3 sepette
Destek (support)	Sepetlerin ne kadarında geçiyor?	sepet(A) / tüm sepetler	Çay 3/3 = 1 · Süt 2/3 · {Çay, Süt} 2/3
Güven (confidence)	A alanların ne kadarı B'yi de aldı?	destek(A, B) / destek(A)	Süt → Çay: 1 · Çay → Süt: 0,67
Kaldıraç (lift)	Birlikte görülme, tesadüften ne kadar fazla?	güven(A → B) / destek(B)	Süt → Çay: 1 / 1 = 1

Sepetler: {Çay, Süt} · {Çay, Ekmek, Süt} · {Çay}

Süt → Çay kuralının güveni %100, ama kaldıraç 1: Çay zaten herkesin sepetinde. Kural yeni bir şey söylemiyor. Kodu gelecek hafta (mlxtend).

Bugün Ne Öğrendik?

1

Temizlik amaca bağlı

Aynı satır bir amaç için çöp, başka bir amaç için veri (boş müşteri numarası).

2

Çalışan kod ≠ doğru sonuç

Hata vermeyen yanlışlar: parantez, yanlış tablo, iptal edilen satış. Sonuca şüpheyle bak.

3

"Popüler" tek sayı değil

Adet, fatura, müşteri: farklı listeler. Ölçüyü sen seçer, gerekçesini yazarsın.

Haftaya kadar

Defterdeki boş hücreler · 4.4'teki gerekçeli ölçü kararı · Kendini sına + ⭐ E1–E8 · Gelecek hafta: sepet analizinin kodu